

张怀民

Foru

评测方法说明书

让“懂分寸”，
成为可以检验的能力。

评测对象：张怀民 Foru 的连续语音交互。区分确定性原型验收、真实声学验证和用户体验研究；本文文件中的性能门槛均为候选目标，不是已取得的实验结果。

在线交互 Demo · 点击链接立即体验

<https://foru-opal.vercel.app>

离线保底：Foru_Demo.zip → 解压 → 双击 index.html

FINAL v2.0 · 2026.09.08

评估维度 / 实验设计 / 指标口径 / 判定标准

01 / 要验证的核心假设

基线采用相同 ASR / TTS / LLM / 工具，仅改变对话策略，控制底层模型影响。

假设	对照设计	主要证据
H1 更会等、更少误打断	A 固定端点与能量打断；B Foru 语义和指向策略	误打断率降低，且漏打断与等待时间不恶化
H2 公共场所更敢用	同样任务；A 固定输出；B 路由与隐私自适应	未授权外放为零；社交顾虑与完成率改善
H3 跨场景无需重述	同一约见任务从训练到驾车、咖啡馆	上下文保留、修复次数、任务完成耗时
H4 记忆带来可控收益	无记忆 / 用户授权记忆，对同类后续任务比较	偏好调用正确、修改生效，用户控制感不下降

北极星：低摩擦连续任务完成率

分子：任务完成，且零严重误执行、零未授权外放，系统错误导致的用户修复不超过一次的会话数。分母：已经显式开启、获得必要权限并具有完整任务目标的合格会话数。

修复包括用户因系统错误重说目标、纠正系统自行改变的参数、重新唤醒；用户自然改主意不算系统修复。网络失败与用户主动放弃分开统计，但网络失败仍计入已启动任务的完成率分母，不能事后剔除美化结果。

02 / 指标必须有清楚的分母

下列门槛为产品候选验收值；使用独立测试集与95%置信区间解释。

指标 / 定义	采集方法	候选门槛
误打断率：非有效插话却导致AI停播的事件 / 所有非有效插话事件	噪声、喘气、背景人声事件标注 + 音频回环	$\leq 3\%$ ，且相对基线下降 $\geq 30\%$
漏打断率：有效插话后500 ms仍未让话的事件 / 所有有效插话事件	双通道录音，人工标注插话起点与实际停声	$\leq 5\%$ ；必须与误打断一起报告
抢话率：用户未结束即开始实质回答的次数 / 所有未结束话轮	两位标注员判断语义和话轮终点	$\leq 5\%$
停止延迟：用户有效插话起点到AI最后可听音频	共同时间轴音频回环；报告P50/P95/P99	$P95 \leq 300\text{ ms}$ ，失败也计入
响应延迟：真实话轮结束到首个有用反馈	排除填充语“嗯”；分文字与声音	$P95 \leq 1.5\text{ s}$ ；避免用抢答换速度
上下文保留率：交接后正确保留的必需字段 / 应保留字段	比较目标、地点、时间、任务版本、确认状态	$\geq 95\%$ ；关键动作参数100%正确

按场景、噪声、设备和说话人分层报告；不能仅展示总体均值。毫秒目标不引用“人类正常阈值”作既定事实，需要真实设备与用户研究共同校准。

03 / 不能被综合分掩盖的底线

隐私、执行与记忆错误单独判定，不能靠自然度评分抵消。

维度	口径与验证	判定标准
未授权外放	未经当前用户允许，经扬声器输出敏感信息的次数；注入断连、切设备、后台切换	测试集0次；任一发生即阻断发布
未确认执行 / 重复执行	草稿未确认即执行，或同一幂等键执行多次；检查外部沙盒回执	0次；篡改参数后旧确认应失效
说过账本正确性	中断后 falsely-heard：未播内容被当作已告知 / 所有中断恢复案例	0次严重错误；边界误差单报
路由策略正确率	策略与人工期望一致的切换 / 全部切换；另报不必要静音	≥95%；隐私失败适用零容忍门槛
记忆调用正确率	适用且未过期的正确偏好调用 / 全部偏好调用	≥95%；拒绝保存后写入0次
修改 / 删除生效	已修改或删除记录在缓存、检索和下次会话中仍被调用	0次；同步传播窗口单独测量
主观自然度 / 控制感	每幕结束1-5分问卷：节奏自然、可打断、可控制	自然度均值≥4；控制感相对基线不下降

“测试集零失败”不代表现实零风险。若600次独立注入事件均无失败，用近似3/n规则，其95%失败率上界约0.5%；同场景高度相关样本需按场景或设备聚类估计。

04 / 三层验证，不混用证据

先验证原型逻辑，再验证声学系统，最后判断用户是否真的受益。

层级	样本与执行方式	能证明 / 不能证明
L0 确定性原型验收	18步剧情 + 12项自动化状态检查；浏览器操作与刷新	能证明状态逻辑与可演示性；不能证明识别率、声学时延
L1 语音与故障实验	3600段对话事件；600次路由 / 确认 / 迟到回包故障注入	能测试真实性能、鲁棒性与底线；不能替代长期用户体验
L2 用户研究	先12人预试；再拟48人交叉对照；后续2周自愿试用	能比较可用性与控制感；正式推断样本量需由预试校准

L1 数据构成

30名说话人 × 6类事件 × 4类场景 × 每类5次 = 3600段。六类为明确插话、本人对旁人说话、喘气 / 咳嗽、语义未完停顿、完整话轮结束、低声 / 耳语。四类为健身房、车内、公共安静空间、居家。正负标签和场景不得混为同一分母。

按说话人18 / 6 / 6划分开发、验证、测试集，对应2160 / 720 / 720段，避免同一人泄漏到调参和测试两侧。不同信噪比与麦克风距离在各组平衡；记录dBA、SNR、设备型号和佩戴状态，不把环境音量当作语音难度的唯一变量。

标注与公平性

两位不知道方案分组的标注员独立标注指向性、话轮终点、插话起点与期望路由；分歧仲裁。目标一致性Cohen $\kappa \geq 0.8$ ；不足时修订标注手册。覆盖口音、音高、说话速度、停顿习惯与不同耳机，不按性别推断偏好。

05 / 用户研究如何执行

研究场景中的驾驶操作在模拟器或静止车辆完成。

实验流程

预试12人用于检查剧本难度、时间负担和方差。正式计划48名具备相关场景经验的参与者，以AB / BA各24人随机交叉；准备两套等价联系人与地点，避免第二遍直接记住答案。每人完成四幕连续任务，控制总时长约45-60分钟。

A与B共用语音底座、声音、工具、设备和网络条件；A采用固定端点、固定输出、每设备独立上下文，B启用Foru策略。体验问卷在每幕后收集，事后访谈以具体失败片段追问。研究对象知道是实验系统；如使用人工代答，要在同意书说明人工介入可能并在结束后解释。

测量	题项 / 行为	分析
任务效率	是否接对入口、消息内容是否正确、修复次数、完成时间	配对比较；以参与者为分析单位
自然度与社交顾虑	“它会在我想说时让出话轮” “我担心突然外放” 1-5分	报告均值、分布和配对差值置信区间
驾驶分心	模拟驾驶中的视线离路时间、操作错误、主观负荷	相对基线不恶化；关注最差场景
信任与控制	“我知道它在听吗” “我能阻止动作吗” “知道如何删记忆吗”	不以拟人感代替可控性

统计与样本量

预注册一个主要指标：低摩擦连续任务完成率。目标提升 ≥ 10 个百分点，95%配对差值区间下界 >0 ；若48人不足以可靠检测该差异，按预试方差、显著性0.05与80%功效重算样本量。其他指标标注探索性并控制多重比较。

06 / 可直接照做的验收脚本

期望结果来自产品规范，而不是事后迎合实现。

ID / 操作	应看到的结果	失败条件
T01 未开启时拟消息	提示开启；无待确认草稿	产生了动作或记录
T02 播报中注入喘气	已呈现与未呈现游标连续	噪声让输出清空或任务改写
T03 “我想想……”	Waiting；无实质抢答	把半句当成完整命令执行
T04 正门播报中改北门	准确保留字幕边界；旧入口作废	继续播旧内容或任务仍为正门
T05 消息取消 / 重复确认	取消无回执；确认至多执行一次	取消后仍发送或重复回执
T06 车机接力	同一Session；目标、时间、版本一致	上下文丢失或双设备重复播报
T07 复杂路口 → 停车	先入队，后恢复一次有效摘要	路口展开闲聊或过期内容恢复
T08 耳机断开	输出与队列取消；保持静默	转扬声器或继续敏感内容
T09 仅本次 / 保存记忆	拒绝不留；保存刷新后可见	自动长期写入或修改不生效
T10 提前结束 / 断网	结束清临时输出；断网不假成功	后台继续发声、执行或造回执

L0字幕与计时可直接检查；T06双设备音频独占、T08实际静音及断网恢复的外部回执仍需在L1接入硬件与沙盒后验证。

07 / 发布判定与本轮证据

完整评测计划和已经执行的检查必须分开呈现。

候选发布规则

第一关：底线测试零严重失败，否则修复后重跑相关风险集。第二关：误打断、漏打断、抢话和停止延迟均达门槛，并逐场景检查。第三关：用户任务完成率有实际改善且置信区间支持，控制感与驾驶负荷未恶化。任一关未通过，则维持实验版本。

灰度与长期观察

先面向自愿用户小流量启用，按场景监控，不以轮次增长作为主要成功信号。2周跟踪偏好调用、删除完成、回退旧模式与主动关闭率；若发生未授权外放或未确认执行，立即关闭相关策略 / 工具，保留经授权的脱敏事件用于定位。

证据	本轮状态	解释
状态机自动检查	12 / 12通过	使用Node直接验证状态转移与关键不变量
完整18步剧情	自动检查通过	关闭时任务完成，消息有模拟回执，偏好按确认保存
页面操作与部署	随交付完成浏览器与在线检查	用于确认界面可操作；不作为真实声学证据
真实语音性能 / 用户A/B	未执行	识别率、毫秒延迟、统计显著性与长期收益均待测

埋点与隐私

建议记录事件类型、单调时间戳、策略原因、状态前后、设备路由、输出偏移、工具版本、确认与回执；默认不保留原始音频或完整敏感文本。原型可导出本地模拟日志，日志中的时刻是UI事件时间，不能用于声学性能结论。

来源：用户的三份设计附件及Flow方案；以上样本量、门槛与实验设计由本版本提出，不声称是行业标准。